



# Expresiones regulares

reg[ular]  
expr[essio]n

Compiladores  
Prof. Luis Enrique Hernández Olvera



## Contenido

- Repaso de definiciones.
- Lenguajes Regulares
- Expresiones regulares
- Operadores de las expresiones regulares

Compiladores  
Prof. Luis Enrique Hernández Olvera

2



## Repasando definiciones

- Un conjunto no vacío y finito de símbolos se conoce como alfabeto ( $\Sigma$ ).
- Una secuencia finita de símbolos de un determinado alfabeto se conoce como palabra sobre dicho alfabeto (a-z).
- Cada símbolo de un alfabeto es una cadena sobre dicho alfabeto.
- La cadena vacía, la cual se denota por el símbolo  $\epsilon$  ( $\lambda$ ), es una palabra sobre cualquier alfabeto.



## Repasando definiciones

- Un **lenguaje** es un conjunto de palabras. Por lo tanto el conjunto  $\{1,12,123,1234,12345\}$  es un lenguaje sobre el alfabeto compuesto por dígitos.
- Si  $\Sigma$  es un alfabeto, también es un lenguaje (El formado por todas las cadenas con un único símbolo).



## Repasando definiciones

- Dado que un lenguaje es un conjunto de cadenas, se puede tener el lenguaje compuesto por ninguna cadena (El lenguaje vacío).
- El lenguaje vacío se denota de la misma forma que el conjunto vacío  $\emptyset$ .



## Repasando definiciones

- $\emptyset$ , el **lenguaje vacío**, es un lenguaje de cualquier alfabeto.
- $\{\epsilon\}$ , el lenguaje que consta sólo de la **cadena vacía**, también es un lenguaje de cualquier alfabeto.
- $\emptyset \neq \{\epsilon\}$ ; el primero no contiene **ninguna cadena** y el segundo sólo tiene **una cadena**.





## Repasando definiciones

- El conjunto de todas las cadenas de un alfabeto  $\Sigma$ , se conoce como **cerradura de  $\Sigma$**  o **lenguaje universal de  $\Sigma$**  y se denota por  $\Sigma^*$ .
- Por ejemplo, si se tiene el alfabeto  $\Sigma=\{1\}$ , entonces:

$$\Sigma^* = \{\epsilon, 1, 11, 111, 1111, 11111, \dots\}$$



## Repasando definiciones

- El conjunto de todas las cadenas de un alfabeto  $\Sigma$  se designa mediante  $\Sigma^*$ .

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \dots$$

- El conjunto de cadenas no vacías del alfabeto  $\Sigma$  se designa como **cerradura positiva  $\Sigma^+$** .
- Por lo tanto las dos equivalencias son:

$$\begin{aligned}\Sigma^+ &= \Sigma^1 \cup \Sigma^2 \cup \Sigma^3 \cup \dots \\ \Sigma^* &= \Sigma^+ \cup \{\epsilon\}.\end{aligned}$$

Recuerda  
 $\Sigma^0 = \{\epsilon\}$



## Lenguajes Regulares

- Los lenguajes regulares sobre un alfabeto pueden ser usados para especificar la construcción de analizadores léxicos (programas que analizan un texto y extraen los lexemas o unidades léxicas) que hay en el mismo.



## Lenguajes Regulares

- Los lenguajes más sencillos que formalmente se consideran son los **lenguajes regulares**.
- Un lenguaje regular se puede generar a partir de lenguajes básicos, con la aplicación de las operaciones de **unión**, **concatenación** y cerradura de Kleene un número finito de veces.



## Lenguajes Regulares

- Los lenguajes regulares se llaman así porque sus palabras contienen “**regularidades**” o repeticiones de los mismos componentes.
- Por ejemplo:
  - $L_1 = \{ab, abab, ababab, abababab, \dots\}$ 
    - En este ejemplo se aprecia que las palabras de  $L_1$  son simplemente repeticiones de “ab” cualquier número de veces. Aquí la “regularidad” consiste en que las palabras contienen “ab” algún número determinado de veces.



## Lenguajes Regulares

Un **lenguaje regular** es un tipo de **lenguaje formal** que satisface las siguientes propiedades:

- **Puede ser reconocido por:**
  - Un autómata finito determinista
  - Un autómata finito no determinista
  - Un autómata de pila
  - Un autómata finito alterno
  - Una máquina de Turing de solo lectura
- **Es generado por:**
  - Una gramática regular
  - Una gramática de prefijos
- **Es descrito por:**
  - Una expresión regular





## Definición formal de lenguaje regular

- Sea  $\Sigma$  un alfabeto. El conjunto de los lenguajes regulares sobre  $\Sigma$  se define recursivamente como sigue:
  - El lenguaje vacío  $\emptyset$  es un lenguaje regular.
  - El lenguaje cadena vacía  $\{\epsilon\}$  es un lenguaje regular.
  - Para todo  $a \in \Sigma$ ,  $\{a\}$  es un lenguaje regular.
  - Si  $A$  y  $B$  son lenguajes regulares, entonces  $A \cup B$ ,  $A \cdot B$  y  $A^*$  son lenguajes regulares.
  - Ningún otro lenguaje sobre  $\Sigma$  es regular.



## Ejemplo

Dado  $\Sigma = \{a, b\}$ , las siguientes afirmaciones son ciertas:

- $\emptyset$  y  $\{\epsilon\}$  son lenguajes regulares
- $\{a\}$  y  $\{b\}$  son lenguajes regulares
- $\{a, b\}$  es un lenguaje regular
- $\{ab\}$  es un lenguaje regular
- $\{a, ab, b\}$  es un lenguaje regular
- $\{a^i \mid i \geq 0\}$  es un lenguaje regular
- $\{a^i b^j \mid i \geq 0 \text{ y } j \geq 0\}$  es un lenguaje regular
- $\{(ab)^i \mid i \geq 0\}$  es un lenguaje regular



## Expresiones regulares

- Una **expresión regular** es una forma abreviada de representar cadenas de caracteres que se ajustan a un determinado patrón. Al **conjunto de cadenas representado por la expresión  $r$**  se lo llama *lenguaje generado por la expresión regular  $r$*  y se escribe  $L(r)$ .
- Una expresión regular se define sobre un alfabeto  $\Sigma$  y es **una cadena formada por caracteres** de dicho alfabeto y por una serie de **operadores**.



## Expresiones regulares

- Las expresiones regulares sirven como lenguaje de entrada de muchos sistemas que procesan cadenas por ejemplo generadores de analizadores léxicos, como Lex o Flex.
- Un generador de analizadores léxicos acepta descripciones de las formas de las unidades lógicas, que son principalmente expresiones regulares, y produce un AFD que reconoce qué unidad lógica aparece a continuación en la entrada.





## Expresiones regulares

Si  $\Sigma$  es un alfabeto, una expresión regular sobre este alfabeto se define de la siguiente forma:

- $\emptyset$  es una expresión regular que denota el lenguaje vacío.
- $\epsilon$  es una expresión regular que denota el lenguaje  $\{\epsilon\}$
- Si  $a \in \Sigma$ ,  $a$  es una expresión regular que denota el lenguaje  $\{a\}$
- Si  $r$  y  $s$  son expresiones regulares, entonces  $r \cup s$ ,  $r \cdot s$  y  $r^*$  también lo son.



## Operadores de las expresiones regulares

- Unión:  $(r+s)$  es una expresión regular que denota el lenguaje  $R \cup S$ .
- Concatenación:  $(rs)$  es una expresión regular que denota el lenguaje  $R \cdot S$
- Clausura:  $r^*$  es una expresión regular que denota el lenguaje  $R^*$ .



## Ejemplos

$$\Sigma = \{0,1\}$$

- $00$  El conjunto  $\{00\}$
- $01^*$  Conjunto de palabras que empiezan por 0 y después tienen una sucesión de unos.
- $(1+10)^*$  Conjunto de palabras en las que los ceros están precedidos siempre por unos.
- $(0+1)^*011$  Conjunto de palabras que terminan en 011



## Ejemplos

$$\Sigma = \{0,1\}$$

- $0^*1^*$  Conjunto de palabras formadas por una sucesión de ceros seguida de una sucesión de unos. Ambas sucesiones pueden ser vacías.
- $00^*11^*$  Conjunto de palabras formadas por una sucesión de ceros seguida de una sucesión de unos. Ninguna de las sucesiones puede ser vacía.

A  $r^*r$  se le denota como  $r^+$ . Por lo que en la última expresión regular quedaría como  $0^+1^+$



## Ejemplos

$$\Sigma = \{a, b\}$$

- $a|b$  denota el lenguaje  $L(a|b) = \{a, b\}$ .
- $(a|b)(a|b)$  denota a  $L((a|b)(a|b))$ , el lenguaje de todas las cadenas de longitud dos sobre el alfabeto  $\Sigma$ .
- $(a|b)(a|b) = aa|ab|ba|bb$
- $L(a^*) = \{\lambda, a, aa, aaa, \dots\}$ , todas las cadenas de cero o más a's.



## Ejemplos

$$(a)|((b)^*(c)) = a|b^*c$$

- Descripción:
  - Conjunto de cadenas que son una sola a o ninguna o más b's seguidas por una c.
- Algunas cadenas del lenguaje:
  - $L(a|b^*c) = \{a, c, bc, bbc, bbbc, bbbbc, \dots\}$





## Ejercicio

Dado  $\Sigma = \{a,b,c\}$  y la E.R.  $c^*(a|bc^*)^*$  ¿Describe el lenguaje de todas las cadenas sobre el  $\Sigma$  que no contiene ninguna subcadena ac es regular?



## Ejercicio (Solución)

Dado  $\Sigma = \{a,b,c\}$  y la E.R.  $c^*(a|bc^*)^*$  ¿Describe el lenguaje de todas las cadenas sobre el  $\Sigma$  que no contiene ninguna subcadena ac es regular?

- $\{c\}, \{a\}, \{b\}$  son L.R. (3)
- $\{c\}^*$  es un L.R. (4, \*)
- $\{b\}\{c\}^*$  es un L.R. (4, ·)
- $\{a\} \cup \{b\}\{c\}^*$  es un L.R. (4, U)
- $(\{a\} \cup \{b\}\{c\}^*)^*$  es un L.R. (4, \*)
- $\{c\}^*(\{a\} \cup \{b\}\{c\}^*)^*$  es un L.R. (4, ·)



## Equivalencias en Expresiones Regulares

- Existen muchas equivalencias con respecto a expresiones regulares basadas en las correspondientes igualdades de lenguajes. Se resumen en el siguiente teorema.
- Sean  $r, s$  y  $t$  expresiones regulares sobre el mismo alfabeto  $\Sigma$ . Entonces:



## Equivalencias en Expresiones Regulares

1.  $r \cup s = s \cup r$
2.  $r \cup \emptyset = r = \emptyset \cup r$
3.  $r \cup r = r$
4.  $(r \cup s) \cup t = r \cup (s \cup t)$
5.  $r\epsilon = \epsilon r = r$
6.  $r\emptyset = \emptyset r = \emptyset$
7.  $(rs)t = r(st)$
8.  $r(s \cup t) = rs \cup rt$
9.  $(r \cup s)t = rt \cup st$

10.  $r^* = r^{**} = r^*r^* = (\epsilon \cup r)^* = r^*(r \cup \epsilon) = (r \cup \epsilon)r^* = \epsilon \cup rr^*$
11.  $(r \cup s)^* = (r^* \cup s^*)^* = (r^*s^*)^* = (r^*s)^*r^* = r^*(sr^*)^*$
12.  $r(sr)^* = (rs)^*r$
13.  $(r^*s)^* = \epsilon \cup (r \cup s)^*s$
14.  $(rs^*)^* = \epsilon \cup r(r \cup s)^*$
15.  $s(r \cup \epsilon)^*(r \cup \epsilon) \cup s = sr^*$
16.  $rr^* = r^*r$



## Ejercicios

- Describa los lenguajes generados por las siguientes expresiones regulares y enumere al menos 7 cadenas de cada lenguaje.  $\Sigma = \{a, b, c, d, e, \dots, z\}$
- $(ab)|(cz)|d^*$
- $a+b+c \mid (b+d)z$
- $(abc)^*z$
- $(a|b)^*|a$
- $(ab)^+ (bc)^+$